

# 3-5. 편미분(Partial Derivatives): 다변수 함수의 미분, 딥러닝에서 사용되는 다변수 최적화와 연결

편미분은 다변수 함수에서 각 변수에 대해 독립적으로 미분하는 과정입니다. 다변수 함수는 여러 입력 변수에 의존하는 함수이기 때문에, 특정 변수에 대한 변화율을 계산할 때 나머지 변수들은 고정된 상태로 고려됩니다.

편미분은 딥러닝에서 다변수 최적화 문제를 해결하는데 필수적인 역할을 합니다.

## 1. 편미분의 정의

다변수 함수  $f(x, y, z, \dots)$ 에서 특정 변수에 대한 편미분을 계산할 때는 그 변수만 변화시키고 나머지 변수들은 고정된다고 가정합니다. 편미분의 표기는 다음과 같습니다.

$$\frac{\partial f}{\partial x}$$

이는 함수  $f$ 를 변수  $x$ 에 대해 미분하되, 나머지 변수들은 상수로 취급한다는 말입니다.

예를 들어, 함수  $f(x, y) = x^2 + 3xy + y^2$ 의 경우

- $x$ 에 대한 편미분은  $\frac{\partial f}{\partial x} = 2x + 3y$
- $y$ 에 대한 편미분은  $\frac{\partial f}{\partial y} = 3x + 2y$

## 2. 딥러닝에서의 편미분

딥러닝에서의 신경망은 다변수 함수로 나타낼 수 있습니다. 네트워크의 각 층의 가중치와 편향은 여러 변수로 구성된 함수로 표현되며, 이 가중치들을 최적화하는 것이 학습 과정의 핵심입니다. 신경망의 손실 함수  $L(\hat{y}, y)$ 는 입력 데이터와 네트워크의 가중치에 의해 결정되므로, 각 가중치에 대한 편미분을 계산하여 경사하강법을 통해 최적화를 진행합니다.

예시 : 단일 층 신경망

가정

- 입력 :  $x_1, x_2$

- 가중치 :  $w_1, w_2$
- 출력 :  $\hat{y} = w_1x_1 + w_2x_2$

손실 함수  $L(\hat{y}, y)$ 를 최적화하려면 각 가중치  $w_1, w_2$ 에 대한 편미분을 계산하여 경사하강법을 사용해 가중치를 업데이트합니다.

### 3. 다변수 최적화와 경사하강법

다변수 최적화에서 목표는 다변수 함수의 최소값을 찾는 것입니다. 신경망의 손실 함수  $L(\theta)$ 에서 매개 변수  $\theta$ 에 대해 손실을 최소화하는 것이 목표입니다. 이를 위해서는 각 변수에 대한 편미분들 계산하여 기울기를 얻고, 기울기의 반대 방향으로 가중치를 조정합니다.

#### 경사하강법(Gradient Descent)

경사하강법은 함수의 기울기를 사용하여 최소값을 찾는 방법입니다. 다변수 함수의 기울기는 모든 편미분들의 벡터로 구성되며, 이를 기울기 벡터(Gradient Vector)라고 부릅니다.

$$\nabla L(\theta) = \left( \frac{\partial L}{\partial \theta_1}, \frac{\partial L}{\partial \theta_2} \dots \right)$$

경사하강법에서는 각 매개변수  $\theta_i$ 를 다음과 같이 업데이트 합니다.

$$\theta_i = \theta_i - \eta \frac{\partial L}{\partial \theta_i}$$

여기서  $\eta$ 는 학습률 입니다.


### 4. 편미분의 예제와 그래프

- 예제함수

다음과 같은 2변수 함수  $f(x, y) = x^2 + y^2$ 을 사용하여 편미분을 계산하고 시각화 하겠습니다.

- $f_x = \frac{\partial f}{\partial x} = 2x$
- $f_y = \frac{\partial f}{\partial y} = 2y$

- 이 함수는 2차원에서 볼록한 형태로 (0, 0)에서 최소값을 가집니다.



- 3D 그래프는  $f(x, y) = x^2 + y^2$  함수의 모양을 직관적으로 보여줍니다. 이 함수는 원형 대칭성을 가지며, 중심에서 최솟값을 가집니다.
- 2D 등고선 그래프는 높이가 일정한 선을 그리며, 각 등고선은 같은 함수 값을 나타냅니다. 중심으로 갈수록 낮은 값을 나타내며, 이는 경사하강법에서 최솟값으로 수렴하는 경향을 보여줍니다.

위의 그래프는 다변수 함수  $f(x, y) = x^2 + y^2$ 에 대한 시각화입니다.

- 3D 그래프는 함수의 표면을 보여주며 이 함수는 원형 대칭성을 가지고 있으며 중심에서 최솟값을 가집니다. 이는 경사하강법을 사용할 때 기울기가 작아지는 방향으로 이동하는 형태를 잘 보여줍니다.
- 2D 등고선 그래프는 높이가 일정한 선을 그려 각 등고선이 같은 함수 값을 나타냅니다. 등고선이 밀집된 부분은 기울기가 큰 부분을 의미하고, 넓은 부분은 완만한 구간을 나타냅니다.

편미분을 통해 함수의 변화율을 계산하고, 경사하강법을 적용하여 함수의 최소값을 찾는 과정에서 이러한 시각화가 유용합니다.

```
import numpy as np
import matplotlib.pyplot as plt
from mpl_toolkits.mplot3d import Axes3D
import sympy as sp
```

```

# 변수 정의
x, y = sp.symbols('x y')

# 함수 정의
f = x**2 + y**2

# 편미분 계산
f_x = sp.diff(f, x)
f_y = sp.diff(f, y)

print(f"x에 대한 편미분: {f_x}")
print(f"y에 대한 편미분: {f_y}")

# 2D 및 3D 그래프용 데이터 생성
x_vals = np.linspace(-5, 5, 400)
y_vals = np.linspace(-5, 5, 400)
X, Y = np.meshgrid(x_vals, y_vals)
Z = X**2 + Y**2

# 3D 그래프
fig = plt.figure(figsize=(12, 6))
ax = fig.add_subplot(121, projection='3d')
ax.plot_surface(X, Y, Z, cmap='viridis')

ax.set_title("3D Plot of  $f(x, y) = x^2 + y^2$ ")
ax.set_xlabel("x")
ax.set_ylabel("y")
ax.set_zlabel("f(x, y)")

# 2D 그래프
ax2 = fig.add_subplot(122)
contour = ax2.contourf(X, Y, Z, cmap='viridis')
fig.colorbar(contour)

ax2.set_title("2D Contour Plot of  $f(x, y) = x^2 + y^2$ ")
ax2.set_xlabel("x")
ax2.set_ylabel("y")

```

```
plt.show()
```

- SymPy를 사용한 편미분 계산 : `sp.diff(f, x)`와 `sp.diff(f, y)`를 사용해  $f(x, y) = x^2 + y^2$ 함수의 편미분을 각각 계산합니다.
- 2D 및 3D 그래프 시각화 : `matplotlib`을 사용하여 함수의 3차원 표면과 2차원 등고선(contour)그래프를 시각화합니다.
  - 3D 그래프에서는 함수  $f(x, y)$ 의 곡면을 시각화합니다.
  - 2D 그래프는 함수의 등고선을 보여주며, 각 높이를 색상으로 구분합니다.